Execução Orçamentária do Governo Federal — Agosto de 2026

Relatório de Análise de Dados

Johan Manochio

Outubro de 2026

Links do Projeto

- **Repositório (código e documentação):**
  https://github.com/Ochion/analise-execucao-orcamentaria-portal-transparencia
- **Dashboard interativo (Looker Studio):**
  https://datastudio.google.com/reporting/12a3e0c7-f740-4e62-9580-958aa2e74560

1. Introdução

Este relatório documenta o processo completo de análise de dados aplicado a uma base de execução orçamentária do Governo Federal brasileiro, cobrindo as quatro etapas de um projeto de análise de dados profissional: seleção dos dados, análise exploratória, tratamento e preparação, e visualização — complementadas por uma modelagem preditiva.

A pergunta de negócio que orientou a análise foi: como está a execução orçamentária do Governo Federal em agosto de 2026 — quais órgãos e categorias de despesa concentram mais gastos, e qual o percentual de execução (liquidado e pago) entre eles?

2. Fase 1 — Seleção dos Dados

Os dados utilizados vêm do módulo de Despesas do Portal da Transparência do Governo Federal (portaldatransparencia.gov.br), fonte pública oficial. O Portal disponibiliza a execução da despesa já dividida em tabelas relacionais — Empenho, Liquidação e Pagamento — ligadas entre si por tabelas-ponte através do campo Código Empenho.

Cada arquivo diário disponibilizado pelo Portal reflete os documentos com última movimentação naquele dia específico. Para obter uma visão representativa do mês completo, os 31 arquivos diários de agosto/2026 foram baixados e concatenados para cada tipo de tabela.

2.1 Tabelas utilizadas

Tabela	Linhas	Colunas	Papel no cruzamento
Empenho	205.378	64	Base principal: dimensões (órgão, favorecido, categoria) e valor original
Liquidação – Empenhos (ponte)	589.428	8	Liga Liquidação ↔ Empenho; traz o valor liquidado
Pagamento – Empenhos (ponte)	814.778	8	Liga Pagamento ↔ Empenho; traz o valor pago

Essas três tabelas atendem com folga aos requisitos mínimos do projeto: três tabelas cruzáveis pelo Código Empenho, coluna de data (Data Emissão) presente, mais de cinco colunas em pelo menos duas tabelas, e mais de cem linhas em todas elas.

2.2 Nota metodológica

Das 31 tabelas diárias de Pagamento, apenas 23 continham registros. A investigação confirmou que as 8 datas ausentes correspondem a finais de semana (exceto 01/08 e 15/08, que tiveram pagamentos pontuais, provavelmente de benefícios com calendário fixo) — ou seja, reflete a ausência real de processamento bancário nesses dias, e não uma falha de coleta.

---

3. Fase 2 — Análise Exploratória

Foram conduzidas cinco análises exploratórias sobre a base de execução: distribuição de valores, detecção de outliers, ranking por órgão, correlação entre valor empenhado e valor pago, e série temporal diária.

3.1 Números gerais do mês

Métrica	Valor
Total empenhado	R$ 696.977.023.837,57
Total liquidado	R$ 436.559.673.379,17 (62,6%)
Total pago	R$ 428.265.352.386,77 (61,4%)
Empenhos com liquidação	83.407 de 205.378
Empenhos com pagamento	66.635 de 205.378

3.2 Principais achados

- **Distribuição fortemente assimétrica:** a mediana do valor dos empenhos é de R$ 4.000, enquanto a média é de R$ 3,39 milhões — puxada por outliers bilionários. A maior concentração de empenhos está entre R$ 3.000 e R$ 8.000.
- **Outliers expressivos:** pelo método do intervalo interquartil (IQR), 31.472 empenhos (15,32%) foram classificados como outliers. Os dez maiores valores individuais são quase todos rolagem de dívida pública mobiliária (Ministério da Fazenda) e benefícios previdenciários (RGPS e BPC).
- **Ranking por órgão:** o Ministério da Fazenda lidera isoladamente com R$ 426,56 bilhões empenhados — mais do triplo do segundo colocado, o Ministério da Previdência Social (R$ 110,17 bilhões). Essa liderança é dominada por operações de dívida pública, não por gasto corrente típico.
- **Correlação empenhado x pago:** o coeficiente de Pearson entre valor empenhado e valor pago é de 0,6585 — uma relação positiva moderada a forte, mas com bastante dispersão, em parte explicada pelos empenhos estimativos (ver adiante).
- **Série temporal:** o volume empenhado cai de forma consistente nos finais de semana e apresenta um pico isolado de R$ 387,28 bilhões em 27/08 — mesma causa dos outliers: rolagem de dívida pública concentrada nesse dia.

3.3 Achados complementares

- **Correntes x Capital:** as Despesas Correntes somam R$ 385,83 bilhões (55,4%) e as Despesas de Capital R$ 311,14 bilhões (44,6%). Porém, cerca de 91% da Despesa de Capital do mês corresponde a amortização de dívida pública, não a investimento em infraestrutura — uma distinção importante para a leitura correta da classificação orçamentária.
- **Empenhos simbólicos:** 531 empenhos (0,26% do total) foram abertos com valor original simbólico (≤ R$ 100), mas tiveram pagamento muito maior. Esses casos se concentram em folha de pagamento (vencimentos, obrigações patronais, aposentadorias, auxílio-alimentação) e serviço da dívida — um padrão conhecido de empenho estimativo/global, reforçado após a abertura. Representam apenas 0,24% do valor total pago no mês (R$ 1,03 bilhão de R$ 428,27 bilhões), não distorcendo os totais gerais.

---

4. Fase 3 — Tratamento e Preparação dos Dados

O tratamento foi guiado pelos próprios achados da análise exploratória: cada inconsistência identificada nos gráficos da Fase 2 foi tratada e documentada nesta etapa.

4.1 Tratamento de inconsistências

- **Duplicatas:** identificados e removidos 4 registros de Código Empenho duplicados entre arquivos diários (mantendo a ocorrência mais recente). Base final: 205.378 empenhos únicos, zero duplicatas.
- **Padronização de texto:** remoção de espaços em branco nas pontas de todos os campos de texto — destaque para quase 200 mil valores no campo Observação e mais de 100 mil no campo Linguagem Cidadã.
- **Padronização de datas:** conversão do campo Data Emissão para formato de data real (ISO), substituindo o texto original.

4.2 Colunas derivadas

Foram criadas quatro colunas derivadas, superando o mínimo de duas exigido pelo projeto:

- % Liquidado — percentual do valor empenhado já liquidado
- % Pago — percentual do valor empenhado já pago
- Estorno ou Cancelamento — sinalizador booleano para empenhos com valor original ≤ 0
- Situação da Execução — classificação categórica do estágio de execução de cada empenho

4.3 Distribuição final da Situação da Execução

Situação	Empenhos	%
Empenhado, Sem Execução	116.740	56,8%
Pago Integralmente	39.508	19,2%
Pago Parcialmente	27.029	13,2%
Liquidado, Aguardando Pagamento	19.507	9,5%
Estorno/Cancelamento	2.594	1,3%

---

5. Fase 4 — Visualização

A base tratada foi carregada no Google BigQuery e conectada ao Looker Studio, onde foi construído um dashboard interativo com cinco visualizações distintas.

5.1 Visualizações do dashboard

- **Gráfico de rosca —** Situação da Execução dos Empenhos.
- **Gráfico de barras —** Top 10 Órgãos por Valor Empenhado.
- **Gráfico de linha —** Evolução Diária do Valor Empenhado.
- **Tabela dinâmica —** Execução por Órgão e Categoria de Despesa (Correntes x Capital).

- **Gráfico de dispersão (escala logarítmica) —** Valor Empenhado x Valor Pago por Elemento de Despesa.

5.2 Interatividade

O dashboard conta com controles de filtro por período, órgão e situação da execução, além de interação cruzada entre os gráficos: selecionar um elemento em qualquer visualização filtra automaticamente as demais.

---

6. Modelagem Preditiva

Como complemento às quatro fases, foi construído um modelo de aprendizado de máquina supervisionado para responder à pergunta: com as informações disponíveis no momento da emissão, é possível prever se um empenho será pago dentro do mês? O modelo foi desenvolvido em Python (scikit-learn) e executado no Google Colab; o código está em modelo_pagamento.py e o notebook, com as saídas, em notebooks/modelo_pagamento.ipynb no repositório.

6.1 Definição do problema e variáveis

- **Alvo:** empenho pago no mês (valor pago maior que zero). 32,8% dos empenhos foram pagos no período.
- **Base de modelagem:** 202.784 empenhos, após remover 2.594 estornos/cancelamentos (valor ≤ 0). Divisão estratificada em 162.227 empenhos para treino e 40.557 para teste.
- **Variáveis:** órgão superior, categoria de despesa, elemento de despesa, função, valor original do empenho (em escala logarítmica), dia do mês e dia da semana da emissão.
- **Prevenção de vazamento:** valor liquidado, percentuais de liquidação/pagamento e situação da execução não foram usados, pois revelariam o próprio alvo.

6.2 Modelos e resultados

Foram comparados dois modelos por validação cruzada (3 folds, métrica ROC-AUC): Regressão Logística (0,8329) e Random Forest (0,8441). O Random Forest foi escolhido e avaliado na base de teste:

Métrica (teste)	Random Forest	Referência
ROC-AUC	0,8446	0,50 (aleatório)
Acurácia	76,2%	67,2% (sempre prever "não pago")
Recall (pago)	80,1%	—
Precisão (pago)	60,3%	—
F1	0,688	—

Matriz de confusão na base de teste: 20.230 verdadeiros negativos, 7.016 falsos positivos, 2.652 falsos negativos e 10.659 verdadeiros positivos. Os gráficos (curva ROC, matriz de confusão e importância das variáveis) estão na pasta saidas_modelo do repositório.

6.3 Interpretação e limitações

- **Desempenho:** o modelo supera com folga a referência e identifica 4 de cada 5 empenhos que serão pagos. A precisão é moderada: cerca de 4 em cada 10 empenhos previstos como pagos não foram pagos no mês. Por isso, é mais útil para priorizar o monitoramento do que para decisões automáticas.
- **Variáveis mais importantes:** elemento de despesa "Material de Consumo" (0,237), Ministério da Defesa (0,102), dia de emissão (0,080), função Defesa nacional (0,075) e função Saúde (0,064). A importância indica o peso da variável no modelo, não a direção do efeito.
- **Limitações:** o recorte é de um único mês. O dia de emissão pesa em parte porque empenhos emitidos no fim do mês tiveram menos tempo para serem pagos (efeito da janela de observação), e não por uma regra de negócio. Um modelo mais robusto usaria vários meses e acompanharia cada empenho por um prazo fixo (por exemplo, 30 dias após a emissão).

---

7. Conclusão

Em agosto de 2026, o Governo Federal empenhou R$ 696,98 bilhões, dos quais 62,6% foram liquidados e 61,4% efetivamente pagos dentro do próprio recorte analisado. O achado mais relevante do projeto é que a liderança do Ministério da Fazenda no ranking de gastos — e boa parte do pico de despesas de capital do mês — não reflete investimento público tradicional, e sim operações de rolagem da dívida pública (principal e juros). Essa distinção é essencial para qualquer leitura correta dos dados de despesas do governo.

Como complemento, o modelo preditivo (Random Forest) mostrou que, apenas com informações conhecidas na emissão, é possível prever se um empenho será pago no mês com ROC-AUC de 0,84 e recall de 80%, acima da referência de 67,2% de acurácia. O perfil da despesa (elemento, órgão e função) pesa mais que o valor empenhado, o que sugere que o tipo de gasto determina o ritmo de pagamento mais que o montante. Como o recorte é de um único mês, o resultado deve ser lido como um ponto de partida para análises com mais meses.

Do ponto de vista metodológico, o projeto reforça que tratamento e análise exploratória de dados funcionam de forma iterativa: os padrões e inconsistências identificados durante a Fase 2 (empenhos simbólicos, registros duplicados, valores com espaços em branco) foram exatamente o que orientou as decisões de tratamento formalizadas na Fase 3.